

Rapport de Qualité des Données — Dataset Médical

Projet TechCorp — Challenge IA · **Rôle** DATA · **Date** 2026-06-30 **Source** `dialogues.parquet`
(dataset `ruslanmv/ai-medical-chatbot`) **Pipeline** `scripts/clean_medical_dataset.py`
(reproductible, seed=42)

1. Synthèse

	Lignes	%
Brut	256 916	100 %
Nettoyé (conservé)	244 504	95,2 %
Écarté	12 412	4,8 %

Dataset prêt pour fine-tuning LoRA, exporté en `train.jsonl` (232 279) / `val.jsonl` (12 225) au format chat (`system` / `user` / `assistant`). Volume estimé : **~54 M tokens**.

2. Schéma & intégrité d'entrée

Colonne	Description	Nulls	Vides
<code>Description</code>	titre/résumé de la question	0	0
<code>Patient</code>	question du patient	0	0
<code>Doctor</code>	réponse du médecin (cible)	0	0

Aucune valeur manquante. Problèmes détectés ci-dessous.

3. Anomalies détectées (contexte « données compromises »)

3.1 ⚠ Empoisonnement par duplication massive — anomalie principale

- **10 378 lignes en doublon exact.**
- Concentration anormale : **5 enregistrements clonés exactement 1 137 fois chacun**, 17 réponses présentes > 100 fois (10 772 lignes au total).
- Une duplication aussi régulière et identique n'est pas naturelle dans un corpus de conversations réelles → signature d'une **injection de doublons** par l'équipe précédente, qui aurait biaisé le fine-tuning (sur-apprentissage de ces 5 réponses).
- **Traitement** : déduplication exacte + déduplication `Patient + Doctor`.

3.2 Réponses tronquées / promotionnelles

- **20 990 réponses** se terminent par un appât de référence tronqué du type « ...consult a sexologist online --> ». Bruit non médical, nuisible à l'apprentissage.
- **Traitement** : suppression de la queue `consult ... online -->` et des flèches `-->`.

3.3 Marqueurs de pseudonymisation

- **3 577** occurrences de « attachment removed to protect patient identity ».
- **Traitement** : suppression du marqueur.

3.4 Artefacts d'encodage / mise en forme

- `\xa0` (espace insécable) : 10 876 · `/` (zero-width) : 112 · balises HTML : 7.
- Espaces multiples : 85 573 lignes.
- **Traitement** : normalisation Unicode **NFKC**, strip HTML, compression des espaces.

3.5 Qualité conversationnelle

- Réponses ultra-courtes non informatives (`Hi.`, `ok`, `what to do next`...).
- **Traitement** : seuils min. (Patient ≥ 15 , Doctor ≥ 25 car.) et max. (anti-collage, 6 000 car.).
- 1 conversation non anglophone retirée (cohérence linguistique du modèle).

4. Détail des suppressions

Raison	Lignes
<code>duplicate_row</code> (doublet exact)	10 378
<code>doctor_too_short</code>	1 940
<code>patient_too_short</code>	40
<code>patient_too_long</code>	35
<code>near_duplicate</code> (Patient+Doctor)	12
<code>doctor_too_long</code>	6
<code>non_english</code>	1
Total	12 412

Toutes les lignes écartées sont conservées avec leur motif dans `medical_dataset/removed_samples.parquet` (auditabilité).

5. Distribution des longueurs (caractères) — avant → après

Colonne	moy. brut	moy. clean	médiane clean	max clean
Description	59	59	55	1 503
Patient	436	436	353	5 969

Colonne	moy. brut	moy. clean	médiane clean	max clean
Doctor	537	528	470	5 581

Le `max` de Patient passe de 17 735 → 5 969 et Doctor de 11 385 → 5 581 (suppression des valeurs aberrantes / collages).

6. Limites connues (résiduel acceptable)

- ~30 réponses contiennent encore `-->` et ~23 le mot *attachment* **en milieu de phrase** (hors motif de fin) — < 0,02 % du corpus, impact négligeable.
- Le dataset reflète la qualité variable de réponses humaines réelles ; ce modèle reste **expérimental, non destiné à la production** (cf. briefing).

7. Livrables DATA

Fichier	Contenu
<code>medical_dataset/medical_clean.parquet</code>	dataset nettoyé (244 504 lignes)
<code>medical_dataset/train.jsonl</code>	232 279 ex. format chat LoRA
<code>medical_dataset/val.jsonl</code>	12 225 ex. de validation
<code>medical_dataset/removed_samples.parquet</code>	lignes écartées + motif (audit)
<code>medical_dataset/data_quality_report.md</code>	ce rapport
<code>scripts/clean_medical_dataset.py</code>	pipeline reproductible

Format chat (prêt pour l'équipe IA / LoRA) :

```
{
  "messages": [
    {
      "role": "system",
      "content": "You are a helpful, careful medical assistant. ..."
    },
    {
      "role": "user",
      "content": "<question patient>"
    },
    {
      "role": "assistant",
      "content": "<réponse médecin>"
    }
  ]
}
```